

GlobeLens AI

Plateforme Intelligente d'Agrégation,
de Clustering Sémantique et de
Cartographie de l'Actualité Internationale

Phases 0–4b Validées

Next.js 15 · FastAPI · Grok AI

PostgreSQL · Redis · Elasticsearch



Plan de la Présentation

SOMMAIRE COMPLET

01

Problème & Vision

Infobésité, benchmark étendu,
positionnement

02

Analyse Solutions Existantes

Comparaison 6 plateformes · 9 critères

03

Architecture Logicielle

Clean Architecture, micro-services Docker

04

Cas d'Utilisation (UML)

Diagramme acteurs · Grand Public · Admin

05

Modèle de Données (MCD)

Entités · Relations · pgvector

06

Ingestion & Intelligence IA

RSS, Clustering, LLM Grok

07

Matrice des Permissions

RBAC · 5 rôles · 11 fonctionnalités

08

Stack Technologique

12 couches · justifications techniques

09

Risques & Mitigation

6 risques classifiés avec stratégies

Le Problème & Notre Vision

AXE 1 — CADRAGE DU PROJET

⚠ LE CONSTAT — L'Infobésité



Fatigue de la redondance

> 80% du contenu répété entre agences



Effondrement du contexte géo

Aucun ancrage visuel sur carte du globe



Instabilité de la traçabilité

Absence de croisement sémantique automatisé



LA VISION GLOBELENS AI

Un hub intelligent qui centralise, nettoie, regroupe et cartographie l'actualité mondiale pour une lecture objective et instantanée.

Centraliser

Nettoyer

Regrouper

Cartographier

BENCHMARK FONCTIONNEL — Positionnement GlobeLens

Fonctionnalité	Google News	GlobeLens AI
Clustering sémantique	Basique	✓ Avancé Cosinus
Détection biais	X Aucune	✓ IA Éthique
Ancrage GPS	X Absent	✓ Natif
Synthèse multi-sources	X Non	✓ Résumé unifié

Analyse des Solutions Existantes

AXE 2 — ÉTUDE DE L'EXISTANT

3 — Comparaison détaillée multi-critères (9 critères clés)

Critère	Google News	AllSides	Ground News	Artifact	Reuters	GlobeLens
Agrégation multi-sources	Oui	Partielle	Oui	Oui	Non	Oui
Synthèse IA	Non	Non	Non	Résumé	Non	Oui
Score fiabilité	Non	Biais seul	Partiel	Non	Non	0-5
Attribution paragraphe	Non	Non	Non	Non	Non	Oui
Timeline événement	Non	Non	Non	Non	Non	Oui
Vue cartographique	Non	Non	Non	Non	Non	Oui
Fact-checker intégré	Non	Non	Non	Non	Non	Oui
Application mobile	Oui	Oui	Oui	Oui	Oui	Oui
Gratuit	Oui	Oui	Partiel	Oui	Oui	Oui

Architecture Logicielle & Écosystème Conteneurisé

AXE 3 — CONCEPTION SYSTÈME

Clean Architecture — 4 couches indépendantes

Exposition (Controllers)

FastAPI · HTTP Routes · OpenAPI docs

Métier (Services)

Scraper · Embedding · Clustering · Auth

Accès Données (Repositories)

PostgreSQL · SQLAlchemy · Async

Domaine (Entities)

User · Article · Event · Embedding · Comment

Couches étanches — zéro couplage technique

Écosystème Docker Compose — 5 micro-services



backend

FastAPI · Python 3.12 · Uvicorn (async)



db

PostgreSQL 16 + pgvector + JSONB



cache

Redis Stack — TTL 5-15 min · hachage MD5



search

Elasticsearch 8.x — fulltext multilingue



frontend

Next.js 15 (App Router) · Leaflet · Mapbox GL

Frise des statuts :

SCRAPED



EMBEDDED




CLUSTERED



PROCESSED

Diagramme de Cas d'Utilisation (UML)

AXE 4 — MODÉLISATION FONCTIONNELLE



Acteurs & Fonctionnalités Clés



Grand Public (GP)

Consulter la Map principale

Rechercher une actualité

Voir score de fiabilité

Consulter synthèse/résumé

Écouter l'article (Listening)

Suivre un événement / Notifs

Consulter la Timeline

Faire un commentaire



Journaliste

S'authentifier (optionnel)

Soumettre/Gérer ses articles

Définir préférences (Topics/Géoloc)



Administrateur

Accéder au Dashboard

Gérer les journalistes

Promouvoir/Masquer articles

Modérer les commentaires


Bloquer/Supprimer utilisateurs

Ajouter des sources

Consulter les statistiques

Modèle Conceptuel de Données (MCD)

AXE 5 — MODÉLISATION DES DONNÉES



Entités principales & Relations

Article	id · title · content · url · published_at source_id · event_id · created_at
Event	id · title (generated) · summary (LLM generated) created_at · updated_at · topic · country
Embedding	id · article_id · vector [1536 dim] stocké via pgvector
Source	id · name · credibility_score · country
User	id · name · email · role (GUEST/AUTH/JOURNALIST/ADMIN)
Comment	id · user_id · event_id · content · created_at
FactCheckRequest	id · user_id · input_text_url · result (true/false/uncertain) · explanation · created_at

Pipeline d'Ingestion & Intelligence IA

AXE 6 — COLLECTE & TRAITEMENT



VECTORISATION — Grok x.AI (1536 dim)

Conversion du texte en vecteur mathématique via API Grok (SDK OpenAI compatible). Cache Redis MD5 pour éviter les appels API redondants. Statut → EMBEDDED.



Cache Redis MD5 — économie API

Si hash MD5 connu → vecteur extrait instantanément sans appel externe.



CLUSTERING — Distance Cosinus pgvector

Opérateur : **Distance Cosinus <=> (pgvector)**

Seuil : **0.18 ≡ 82% similarité minimale**

Fenêtre : **72 heures glissantes max**

$d < 0.18$ → **Rattaché à l'Event existant**

$d \geq 0.18$ →

Nouvel Event créé • Statut → CLUSTERED

Matrice des Permissions par Acteur (RBAC)

AXE 7 — SÉCURITÉ & CONTRÔLE D'ACCÈS

6.4 — Matrice complète des droits d'accès — 5 rôles × 11 fonctionnalités

Fonctionnalité	Guest	Auth.	Journalist	Admin	Système
Lire le feed & articles	Oui	Oui	Oui	Oui	-
Recherche / filtres	Oui	Oui	Oui	Oui	-
Score fiabilité	Oui	Oui	Oui	Oui	Calcul auto
Vue cartographique	Non	Oui	Oui	Oui	Mapbox
Timeline événement	Oui	Oui	Oui	Oui	-
Commenter / analyser	Non	Oui	Oui	Oui	-
Fact-checker	Non	Oui	Oui	Oui	IA analyse
Soumettre du contenu	Non	Non	Oui	Oui	-
Scraping automatique	-	-	-	-	Cron 30 min
Synthèse IA	-	-	-	-	Grog API
Modération & admin	Non	Non	Non	Oui	-



Stack Technologique — 12 couches

AXE 8 — CHOIX TECHNIQUES

7.1 — Justifications techniques de chaque composant

Couche	Technologie	Justification
Backend API	Python FastAPI	Async natif, performances élevées, écosystème IA riche
Base de données	PostgreSQL + JSONB	Schéma relationnel + stockage JSON flexible pour body synthétisé
Moteur de recherche	Elasticsearch 8.x	Full-text multilingue, filtres géo, date, topic simultanés
Cache	Redis	TTL 5-15 min sur articles synthétisés, invalidation par topic
IA Synthesis	Grog (Llama 3.3 70B)	Gratuit en développement, compatible OpenAI API, faible latence
Scraping	feedparser + Playwright	RSS pour sources standards, Playwright pour pages dynamiques JS
Queue / Scheduler	APScheduler (async)	Cron toutes les 30 min, retry automatique avec backoff
Frontend Web	Next.js 15 (App Router)	SSR pour SEO, React Query pour état serveur
Mobile	React Native + Expo	Cross-platform iOS/Android, même API backend
Cartographie	Mapbox GL JS	Clusters de pays, marqueurs géo pour DualView
Notifications	Firebase FCM	Push iOS et Android pour alertes topics
Monitoring	Sentry + Grafana	Erreurs temps réel + métriques scraping et API

Risques & Stratégies de Mitigation

AXE 9 — GESTION DES RISQUES

8 — Matrice des risques identifiés — criticité et réponses opérationnelles

Risque	Criticité	Stratégie de Mitigation
Scraping légal	HAUTE	Priorité RSS, vérification robots.txt, Crawl-delay respecté, partenariats sources envisagés
Coût API IA	MOYENNE	Grog gratuit en dev, Haiku pour clustering en prod, alerte budget dès J1, cache Redis agressif
Mobile en retard	HAUTE	Chaque feature Phase N développée en parallèle web + mobile dans le même sprint
Qualité synthèse	MOYENNE	Prompt versioning en base, A/B test prompts, validation JSON côté serveur
Scalabilité ES	FAIBLE	Index mapping défini en Phase 0, pagination systématique (max 100), geo_point natif
Sécurité données	MOYENNE	JWT + refresh tokens, secrets en variables d'env, jamais en code source

Légende des criticités :

HAUTE

MOYENNE

FAIBLE

Enrichissement Cognitif IA & Recherche Instantanée

AXE 6 (suite) — INTELLIGENCE AUGMENTÉE



SYNTHÈSE OBJECTIVE — LLMService (Grok / Llama 3.3 70B)

- ▶ Lecture croisée de toutes les sources d'un même Event
- ▶ Élimination des biais subjectifs et politiques (format JSON Pydantic)
- ▶ Rédaction d'une synthèse neutre en 3 paragraphes
- ▶ Extraction : Thème · Pays · Coordonnées GPS (Lat/Long précis)



Elasticsearch 8.x

Index plein texte sur Events.
Autocomplétion instantanée.
Filtres géo + date + topic.

< 50 ms

latence de recherche

DONNÉES STRUCTURÉES EXTRAITES PAR L'IA → Format JSON de sortie validé par Pydantic

```
{ "theme": "Géopolitique", "country": "IN", "lat": 28.6139, "lng": 77.2090, "summary": "...", "status":  
"PROCESSED", "credibility_score": 4.2 }
```

Expérience Utilisateur & Sécurité Applicative

AXE 7 (suite) — PRODUIT FINI

Interface Cartographique (Next.js 15 + Mapbox GL)

L'utilisateur ouvre une carte du monde interactive. Chaque événement enrichi par l'IA est positionné sous forme de marqueur GPS cliquable avec score de fiabilité.

-  Marqueurs GPS cliquables par Event
-  Fiche synthèse IA — 3 paragraphes neutres
-  Score de fiabilité 0-5 affiché
-  Timeline chronologique des sources
-  Recherche + autocomplétion Elasticsearch
-  Notifications push Firebase FCM
-  Écoute article (Text-to-Speech)
-  App mobile React Native + Expo

Sécurité RBAC — 4 niveaux de rôles

GUEST

Lecture feed, map (non), synthèses publiques

AUTH_USER

Commentaires · Suivi · Notifs · Fact-checker

JOURNALIST

Soumission & gestion d'articles propres

ADMIN

Dashboard complet · Scraping · Clustering · Modération

EN RÉSUMÉ

9

Axes
présentés

5

Micro-services
Docker

1536

Dimensions
d'embedding

82%

Similarité
minimale

12

Couches
stack techno

GlobeLens AI

Plateforme de nouvelle génération pour une information claire, géolocalisée et débiaisée.



Architecture solide

Clean Architecture 4 couches + Docker Compose 5 services



IA de pointe

Grok Llama 3.3 70B + embeddings 1536 dim + pgvector



UX innovante

Mapbox GL interactive + React Native cross-platform



Sécurité robuste

JWT + bcrypt + RBAC 4 niveaux + Firebase FCM



Monitoring & Risques

Sentry + Grafana + 6 risques mitigés dès J1